



# UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

*Facultad de Ciencias*

---

## Reconocimiento de Patrones y Aprendizaje Automatizado

### Proyecto Final

---

## Análisis de Cardiotocografía Fetal mediante Clustering

*Presenta:*

Hernández Zavala Ana Sofía  
Ramírez Juárez María Fernanda  
Rojo Peña Manuel Ianluck

*Profesor:*

Sergio Rodolfo Cruz Gómez

*Ayudantes:*

Gustavo Adolfo Garduño Martínez  
Julio César Misael Monroy González

Grupo: 7142, 2026-2

*Fecha de entrega:*

24 de mayo, 2026

# Índice

|           |                                                           |           |
|-----------|-----------------------------------------------------------|-----------|
| <b>1</b>  | <b>Introducción</b>                                       | <b>3</b>  |
| <b>2</b>  | <b>Participantes</b>                                      | <b>3</b>  |
| <b>3</b>  | <b>Descripción del Problema</b>                           | <b>3</b>  |
| 3.1       | Contexto y motivación . . . . .                           | 3         |
| 3.2       | Descripción del problema . . . . .                        | 4         |
| 3.3       | Justificación del dataset . . . . .                       | 4         |
| 3.4       | Objetivo general . . . . .                                | 4         |
| <b>4</b>  | <b>Descripción del Dataset</b>                            | <b>4</b>  |
| 4.1       | Fuente y dimensiones . . . . .                            | 4         |
| 4.2       | Variables de entrada . . . . .                            | 4         |
| 4.3       | Variable objetivo y distribución de clases . . . . .      | 5         |
| 4.4       | Retos del dataset . . . . .                               | 5         |
| <b>5</b>  | <b>Preprocesamiento</b>                                   | <b>7</b>  |
| 5.1       | Auditoría y limpieza . . . . .                            | 7         |
| 5.2       | Tratamiento de outliers . . . . .                         | 7         |
| 5.3       | Análisis de correlaciones . . . . .                       | 8         |
| 5.4       | Normalización y estandarización . . . . .                 | 9         |
| 5.5       | Reducción de dimensionalidad (PCA) . . . . .              | 10        |
| <b>6</b>  | <b>Modelos de Clustering</b>                              | <b>10</b> |
| 6.1       | K-Means++ (clustering particional) . . . . .              | 11        |
| 6.2       | DBSCAN (clustering basado en densidad) . . . . .          | 11        |
| 6.3       | Gaussian Mixture Models (modelo probabilístico) . . . . . | 12        |
| 6.4       | Tabla comparativa de algoritmos . . . . .                 | 13        |
| <b>7</b>  | <b>Métricas de Evaluación</b>                             | <b>14</b> |
| 7.1       | Métricas internas . . . . .                               | 14        |
| 7.2       | Métricas externas . . . . .                               | 14        |
| <b>8</b>  | <b>Resultados de Clustering</b>                           | <b>15</b> |
| 8.1       | K-Means++ . . . . .                                       | 15        |
| 8.2       | DBSCAN . . . . .                                          | 16        |
| 8.3       | GMM . . . . .                                             | 17        |
| 8.4       | Tabla comparativa de métricas de clustering . . . . .     | 19        |
| <b>9</b>  | <b>Modelos de Clasificación Supervisada</b>               | <b>21</b> |
| 9.1       | K-Nearest Neighbors (KNN) . . . . .                       | 21        |
| 9.2       | Árbol de Decisión . . . . .                               | 22        |
| 9.3       | Perceptrón Multicapa (MLP) . . . . .                      | 23        |
| 9.4       | Fronteras de decisión en PCA 2D . . . . .                 | 25        |
| 9.5       | Tabla comparativa de clasificadores . . . . .             | 26        |
| <b>10</b> | <b>Análisis y Conclusiones</b>                            | <b>26</b> |

---

|           |                                                   |           |
|-----------|---------------------------------------------------|-----------|
| 10.1      | Análisis de resultados de clustering . . . . .    | 26        |
| 10.2      | Análisis de resultados de clasificación . . . . . | 27        |
| 10.3      | Conclusiones sobre los modelos . . . . .          | 27        |
| 10.4      | Limitaciones . . . . .                            | 28        |
| 10.5      | Sugerencias para trabajos futuros . . . . .       | 28        |
| <b>11</b> | <b>Notebooks de Google Colab</b>                  | <b>28</b> |

---

## 1. Introducción

---

La mortalidad infantil y materna representa uno de los indicadores más sensibles del nivel de desarrollo humano. Los Objetivos de Desarrollo Sostenible de las Naciones Unidas establecen como meta para 2030 la eliminación de las muertes prevenibles de recién nacidos, mientras que en 2017 aproximadamente 295,000 mujeres fallecieron durante o tras el embarazo, concentrándose el 94 % de esos casos en entornos de bajos recursos.

En este contexto, la Cardiotocografía (CTG) emerge como herramienta diagnóstica accesible, no invasiva y de bajo costo que permite monitorear el estado de salud fetal durante la gestación. Mediante el análisis de pulsos de ultrasonido, un equipo CTG registra la frecuencia cardíaca fetal (FCF), los movimientos del feto y las contracciones uterinas.

El presente proyecto aplica técnicas de **clustering no supervisado** sobre un conjunto de registros CTG para identificar agrupaciones naturales en el comportamiento fisiológico fetal, y complementa el análisis con **modelos de clasificación supervisada** para predecir el estado de salud fetal a partir de las mismas variables. A lo largo de las secciones exploramos el preprocesamiento, la implementación de tres algoritmos de agrupamiento (K-Means++, DBSCAN y GMM), tres clasificadores (KNN, Árbol de Decisión y MLP) y la comparación de resultados con métricas internas, externas y de clasificación.

---

## 2. Participantes

---

El equipo está integrado por tres estudiantes de la Facultad de Ciencias de la UNAM (Grupo 7142, semestre 2026-2), cada uno con un rol claramente delimitado:

- **Hernández Zavala Ana Sofía** (Lic. Matemáticas Aplicadas). Especialista en preprocesamiento de datos. Responsable de la auditoría, limpieza, normalización y transformación del dataset para dejarlo listo para los modelos.
- **Ramírez Juárez María Fernanda** (Lic. Ciencia de Datos). Analista de modelos. Encargada de implementar y evaluar los modelos de clustering e implementar las métricas de evaluación internas y externas.
- **Rojo Peña Manuel Ianluck** (Ing. Sistemas Computacionales). Líder de equipo. Coordinador del proyecto y responsable de los modelos de clasificación supervisada.

---

## 3. Descripción del Problema

---

### 3.1 Contexto y motivación

Abordar el análisis de registros de cardiotocografía desde una perspectiva de aprendizaje no supervisado resulta especialmente interesante porque, a diferencia de la clasificación

supervisada, el clustering explora la estructura *natural* de los datos sin imponer categorías a priori. Esto permite descubrir agrupaciones que no necesariamente coincidan con las clasificaciones diagnósticas convencionales.

### 3.2 Descripción del problema

El dataset contiene 2,126 registros de exámenes CTG, cada uno descrito por 21 variables numéricas relacionadas con la dinámica cardíaca fetal y propiedades estadísticas del histograma de frecuencia. Cada registro cuenta además con una etiqueta de clase asignada por tres obstetras expertos que categoriza el estado fetal como **Normal**, **Sospechoso** o **Patológico**. Esta etiqueta no participa en el entrenamiento de los modelos de clustering, aunque sí sirve como referencia externa para evaluar la coherencia clínica de los grupos descubiertos.

### 3.3 Justificación del dataset

Seleccionamos el dataset *Fetal Health Classification* (Kaggle, basado en Ayres de Campos et al., 2000) por tres razones complementarias. Primero, el impacto social de aplicar ciencias de la computación a la salud perinatal. Segundo, la naturaleza técnicamente limpia pero desafiante del conjunto: variables puramente numéricas sin valores faltantes permiten centrar los esfuerzos en la experimentación algorítmica. Tercero, la coexistencia de variables con magnitudes radicalmente distintas (frecuencia cardíaca basal entre 106 y 159 lpm frente a tasas de aceleración en milésimas de segundo) ofrece un entorno real para evaluar técnicas de estandarización y reducción de dimensionalidad.

### 3.4 Objetivo general

Aplicar y comparar tres métodos de clustering sobre el dataset CTG para identificar agrupaciones naturales, evaluar su coherencia interna mediante métricas especializadas, contrastar los resultados con las categorías diagnósticas de referencia, y complementar con clasificadores supervisados para determinar en qué medida el aprendizaje automático es capaz de recuperar la estructura clínica subyacente.

## 4. Descripción del Dataset

---

### 4.1 Fuente y dimensiones

El dataset proviene de Kaggle bajo el título *Fetal Health Classification*. Su origen científico es el estudio de Ayres de Campos et al. (2000), publicado en el *Journal of Maternal-Fetal Medicine*. Está compuesto por **2,126 observaciones** y **22 columnas**: 21 variables de entrada derivadas del análisis CTG y una columna `fetal_health` con la etiqueta clínica. No existen valores faltantes.

### 4.2 Variables de entrada

Todas las variables son numéricas. Dentro del conjunto conviven variables continuas (aceleraciones, movimientos, contracciones, desaceleraciones) y variables discretas (estadísticos


del histograma de FCF: ancho, mínimo, máximo, picos, ceros, moda, media, mediana, varianza). La Tabla 1 resume las más relevantes.

**Cuadro 1:** Selección de variables del dataset CTG con rango aproximado.

| Variable                        | Tipo     | Rango aprox. | Observaciones clave                              |
|---------------------------------|----------|--------------|--------------------------------------------------|
| baseline_value                  | Discreta | 106–159 bpm  | FCF basal; mayor magnitud absoluta del dataset   |
| accelerations                   | Continua | 0.000–0.018  | Alta presencia de ceros; rango reducido          |
| fetal_movement                  | Continua | 0.000–0.481  | Distribución fuertemente asimétrica              |
| severe_decelerations            | Continua | 0.000–0.001  | Casi constante en 0.0 (solo 5 valores distintos) |
| abnormal_short_term_variability | Discreta | 16–87 %      | Buen rango de variación                          |
| histogram_mode / mean / median  | Discreta | 71–167       | Multicolinealidad elevada entre los tres         |
| histogram_variance              | Discreta | 0–215        | Alta dispersión; outliers extremos               |
| histogram_tendency              | Discreta | –1, 0, 1     | Variable ordinal categórica codificada           |

### 4.3 Variable objetivo y distribución de clases

La columna `fetal_health` toma tres valores: 1 = Normal, 2 = Sospechoso, 3 = Patológico. Su distribución está marcadamente desbalanceada: la clase Normal concentra aproximadamente el 78 % de los registros, mientras que Sospechoso y Patológico representan el 14 % y el 8 % restantes (Figura 1).



**Figura 1:** Distribución de clases en el dataset CTG. Izquierda: conteo absoluto. Derecha: proporción porcentual.

### 4.4 Retos del dataset

Identificamos cinco desafíos metodológicos con implicaciones directas sobre el preprocesamiento y la elección de algoritmos:

- Desbalance de clases.** El 78 % de los registros pertenecen a la clase Normal, lo que puede llevar a que los algoritmos basados en distancia absorban los casos de Sospechoso y Patológico al grupo mayoritario.

- 
- B. **Heterogeneidad de escalas.** `baseline_value` opera en el rango 100–160 mientras que `accelerations` lo hace en 0.000–0.018. Sin estandarización, cualquier cálculo de distancia sobrepondera la primera variable.
  - C. **Multicolinealidad.** `histogram_mode`, `histogram_mean` y `histogram_median` son representaciones distintas de la misma señal cardíaca, con correlaciones típicamente superiores a 0.90 entre ellas.
  - D. **Variables con baja varianza.** `severe_decelerations` es prácticamente constante (5 registros con valor distinto de cero sobre 2,126).
  - E. **Outliers.** `histogram_variance` presenta valores extremos superiores a 120 mientras la mayoría se encuentra por debajo de 10.

## 5. Preprocesamiento


### 5.1 Auditoría y limpieza

Comenzamos verificando programáticamente la completitud del dataset. Se confirmó la ausencia de valores nulos, valores centinela ( $-999$ ) y cadenas vacías en las 22 columnas. Adicionalmente, identificamos y eliminamos registros duplicados exactos para evitar sesgar los centroides de K-Means hacia regiones sobrerrepresentadas.

La consistencia de rangos clínicos se verificó para las variables con límites fisiológicamente definidos (`baseline_value` entre 50 y 200, porcentajes entre 0 y 100, `fetal_health` entre 1 y 3). No se encontraron registros fuera de rango.

### 5.2 Tratamiento de outliers

Empleamos el criterio del rango intercuartílico (IQR): todo valor por debajo de  $Q_1 - 1,5 \cdot \text{IQR}$  o por encima de  $Q_3 + 1,5 \cdot \text{IQR}$  se consideró candidato a outlier (Figura 2). La decisión sobre su tratamiento dependió del contexto clínico: los outliers asociados a casos Patológicos se conservaron para no sesgar el análisis hacia los grupos mayoritarios.



**Figura 2:** Boxplots de las variables con mayor número de outliers. Las cajas comprimidas en cero de `prolongued_decelerations` y `fetal_movement` reflejan la infrecuencia clínica de esos eventos.


Variables como `histogram_number_of_zeroes`, `prolongued_decelerations` y `fetal_movement` presentan la caja comprimida cerca de cero con outliers dispersos hacia arriba, lo que es clínicamente esperable: las desaceleraciones prolongadas y los movimientos fetales intensos son eventos poco frecuentes. Por contraste, `percentage_of_time_with_abnormal_long_term_variability` muestra una caja más amplia con una concentración de outliers entre 70 y 95, lo que sugiere una subpoblación con variabilidad anormal elevada. Las variables del histograma como `histogram_variance` presentan dispersión moderada con outliers en ambos extremos. En todos los casos optamos por conservar estos valores extremos ya que representan registros



clínicos reales, aplicando en su lugar transformaciones logarítmicas para reducir el efecto de las colas sin perder información.

### 5.3 Análisis de correlaciones

Construimos la matriz de correlación de Pearson para confirmar empíricamente la multicolinealidad anticipada (Figura 3). Los pares con correlación absoluta superior a 0.85 incluyen `histogram_mode`, `histogram_mean` y `histogram_median`, lo que justifica la reducción de dimensionalidad con PCA.



**Figura 3:** Matriz de correlación de Pearson de las 21 variables de entrada. El bloque superior derecho concentra las correlaciones más altas entre variables del histograma.

El heatmap confirma la redundancia esperada entre las variables del histograma de FCF. Los pares `histogram_median`–`histogram_mean` ( $r = 0,95$ ), `histogram_median`–`histogram_mode` ( $r = 0,93$ ) y `histogram_mean`–`histogram_mode` ( $r = 0,89$ ) presentan correlaciones muy altas porque las tres son medidas de tendencia central de la misma distribución. De manera similar, `histogram_min` y `histogram_max` muestran correlación negativa fuerte ( $r = -0,90$ ) con otras variables del histograma, ya que los extremos están intrínsecamente ligados al ancho de la distribución. Las variables de eventos clínicos (aceleraciones, contracciones, desaceleraciones) muestran correlaciones bajas entre sí, lo que indica que aportan información complementaria y


no redundante. Esta multicolinealidad justifica el uso de PCA para reducir la dimensionalidad sin perder información relevante.

## 5.4 Normalización y estandarización

Dado que K-Means, DBSCAN y el clustering jerárquico operan sobre distancias euclidianas, la diferencia de escalas es uno de los problemas más críticos. Aplicamos la siguiente estrategia en dos pasos:

1. **Transformación logarítmica**  $\log(x + 1)$  sobre las variables con distribución fuertemente asimétrica y alta esparsidad (`fetal_movement`, `prolongued_decelerations`, `histogram_variance`).
2. **Estandarización Z-score** (media 0, desviación estándar 1) sobre la totalidad de las variables transformadas.

La Figura 4 muestra las distribuciones resultantes tras el preprocesamiento completo.




**Figura 4:** Distribuciones de las 21 variables estandarizadas tras el preprocesamiento. Se distinguen tres grupos de comportamiento según la forma resultante de cada histograma.

La transformación logarítmica tuvo un efecto variable según la naturaleza de cada columna. Para `histogram_variance` y `light_decelerations` la mejora es notable: la distribución pasa de una cola larga hacia la derecha a una forma más extendida y simétrica. Para

`fetal_movement`, `severe_decelerations` y `prolongued_decelerations`, la concentración en cero persiste incluso tras la transformación, lo que refleja que la mayoría de los registros genuinamente registran ausencia de esos eventos clínicos. Tras la estandarización Z-score, los histogramas verdes permiten distinguir tres tipos de comportamiento: variables con distribución aproximadamente normal (`baseline_value`, `histogram_min`, `histogram_mean`), variables con sesgo positivo moderado (`accelerations`, `uterine_contractions`), y variables con alta concentración en un único valor que reflejan la infrecuencia intrínseca de ciertos eventos clínicos. El dataset queda así sin valores faltantes, con outliers atenuados y todas las variables en la misma escala.

### 5.5 Reducción de dimensionalidad (PCA)

Aplicamos PCA con umbral de varianza del 95 % para determinar el número mínimo de componentes necesarios. Los algoritmos de clustering operaron tanto sobre el espacio original estandarizado como sobre los componentes principales para comparar si la reducción mejora la separabilidad.



**Figura 5:** Varianza explicada acumulada por componente principal. La línea roja marca el umbral del 95 %. Se requieren 13 componentes para alcanzarlo.

La curva muestra que ningún componente domina de forma clara: el primero explica apenas el 30 % y la curva crece de forma gradual y continua sin un codo pronunciado. Para alcanzar el umbral del 95 % son necesarios 13 componentes sobre los 21 originales, indicando que la información está distribuida de manera relativamente uniforme entre las variables. Esta ausencia de un quiebre abrupto anticipa que los algoritmos operarán en un espacio intrínsecamente de alta dimensión. Para las visualizaciones utilizamos los dos primeros componentes (PC1 y PC2, aproximadamente el 47 % acumulado) como proyección exploratoria, sin pretender que representen la geometría completa del espacio.

## 6. Modelos de Clustering

La selección de algoritmos no es arbitraria: cada método hace supuestos distintos sobre la forma, densidad y distribución de los datos. Implementamos tres paradigmas complementarios que cubren el espacio de estrategias de agrupamiento más relevantes para este problema.


### 6.1 K-Means++ (clustering particional)

K-Means++ extiende el K-Means clásico mejorando el procedimiento de inicialización: los centroides iniciales se eligen de forma que estén lo más separados posible entre sí, evitando convergencia a mínimos locales subóptimos. Dado un número  $k$  de clusters, el algoritmo minimiza iterativamente la inercia (suma de distancias cuadráticas de cada punto a su centroide más cercano):

$$\mathcal{J} = \sum_{i=1}^N \left\| \mathbf{x}_i - \boldsymbol{\mu}_{c(i)} \right\|^2$$

Su aplicación en este dataset se justifica por tres razones: conocemos de antemano que el problema tiene tres categorías clínicas (valor de  $k$  biológicamente motivado), es computacionalmente eficiente con 2,126 registros y 21 variables, y sus centroides en el espacio estandarizado pueden interpretarse clínicamente. Su limitación principal es que asume clusters de forma esférica y tamaño similar, lo que puede no reflejar la geometría real.

**Selección de  $k$ .** El método del codo y la curva de Silhouette promedio para  $k \in \{2, \dots, 8\}$  se muestran en la Figura 6.




**Figura 6:** Método del codo (inercia WCSS) y Silhouette Score promedio para K-Means++ con  $k = 2, \dots, 8$ . La línea roja indica  $k = 3$ .

La inercia WCSS decrece de forma continua y sin un quiebre pronunciado entre  $k = 2$  y  $k = 8$ , lo que refleja la naturaleza gradual de las fronteras entre los estados de salud fetal. La curva de Silhouette muestra su valor máximo en  $k = 2$  (0.194) y cae a 0.179 en  $k = 3$ , manteniéndose por debajo de ese nivel para  $k \geq 4$ . Aunque el Silhouette sugeriría  $k = 2$  de forma puramente geométrica, la existencia de tres categorías clínicas con sustento médico claro (Normal, Sospechoso, Patológico) motiva la elección de  $k = 3$ . Ambas curvas coinciden en que valores mayores no aportan separabilidad adicional.

## 6.2 DBSCAN (clustering basado en densidad)

DBSCAN identifica regiones del espacio donde los puntos se encuentran densamente agrupados y declara como ruido (*noise*) a los puntos que no pertenecen a ninguna región densa. Requiere dos hiperparámetros:  $\varepsilon$  (radio de vecindad) y `min_samples` (mínimo de puntos para constituir un núcleo). Su elección responde directamente a uno de los retos del dataset: la presencia de variables con distribuciones extremadamente asimétricas y esparsas. DBSCAN es el único algoritmo del conjunto capaz de tratar registros extremos de forma explícita, clasificándolos como ruido en lugar de absorberlos al grupo más cercano.

**Calibración de hiperparámetros.** Para determinar  $\varepsilon$  calculamos la distancia al vecino  $k = 41$  ( $= 2 \cdot 21 - 1$ ) para cada punto del dataset, ordenando los resultados de mayor a menor (Figura 7). El percentil del 2 % de puntos más alejados sugiere un codo en  $\varepsilon_0 \approx 6,3$ . Sobre ese valor se realizó un grid search en la rejilla  $\varepsilon \in [0,5\varepsilon_0, 2\varepsilon_0]$  y `min_samples`  $\in \{5, 10, 15, 20, 30\}$ , resultando en la configuración final  $\varepsilon = 3,155$  y `min_samples`  $= 5$ .




**Figura 7:** Curva de distancias al vecino 41 ( $k = 41$ ) para calibrar  $\varepsilon$  en DBSCAN. La curva cae abruptamente en los primeros  $\sim 100$  puntos (de 18 a 6) y luego decrece de forma suave. La línea roja discontinua marca el codo sugerido en  $\varepsilon_0 \approx 6,3$  (percentil 2 % de puntos más alejados).

La caída pronunciada en los primeros 100 puntos corresponde a los outliers del dataset (registros con vecinos muy lejanos), mientras que la cola suave desde el punto 200 hasta el 2126 indica que la gran mayoría de los registros se encuentran en regiones de densidad relativamente uniforme. El codo en  $\sim 6,3$  marca la frontera entre la zona de ruido y la zona de alta densidad, aunque el grid search final seleccionó  $\varepsilon = 3,155$ , valor más conservador que fuerza una densidad mínima más estricta.

## 6.3 Gaussian Mixture Models (modelo probabilístico)

Los Modelos de Mezcla Gaussiana (GMM) estiman la probabilidad de que cada observación pertenezca a cada uno de los  $k$  componentes gaussianos mediante el algoritmo Expectation-Maximization (EM). La ventaja más relevante para un dominio médico es la **salida probabilística**: en lugar de asignar un feto al cluster 2, el modelo indica que ese registro tiene, por ejemplo, un 65 % de probabilidad de corresponder al grupo Sospechoso y un 35 % al Patológico. Esta ambigüedad cuantificada es clínicamente más honesta en los casos límite donde la transición entre estados no es abrupta.

La flexibilidad de la matriz de covarianza permite clusters de forma elíptica (más realista en un espacio de alta dimensión donde las variables no son independientes) y la selección del número óptimo de componentes se apoya en los criterios BIC y AIC (Figura 8).



**Figura 8:** BIC y AIC para GMM con  $k = 2, \dots, 7$  componentes. Ambos criterios decrecen continuamente; la línea roja punteada marca  $k = 3$  elegido por motivación clínica.

A diferencia del caso ideal en que el BIC presenta un mínimo claro, aquí ambos criterios decrecen de forma continua desde  $k = 2$  hasta  $k = 7$ : el BIC pasa de valores cercanos a cero en  $k = 2$  hasta aproximadamente  $-42,000$  en  $k = 7$ , mientras que el AIC desciende de manera aún más pronunciada. Esto indica que, desde la perspectiva puramente estadística, el modelo siempre mejora su ajuste al añadir más componentes. La elección de  $k = 3$  no está respaldada por un mínimo del BIC sino por la estructura clínica del problema (tres estados de salud fetal reconocidos médicamente) y por la necesidad de mantener una partición interpretable. Este resultado refuerza la idea de que el dataset no presenta una separación gaussiana nítida en tres grupos, sino una estructura continua cuya discretización en tres categorías es una convención diagnóstica más que una propiedad geométrica intrínseca.

## 6.4 Tabla comparativa de algoritmos

**Cuadro 2:** Comparativa de los tres algoritmos de clustering implementados.

| Criterio             | K-Means++                | DBSCAN                     | GMM                            |
|----------------------|--------------------------|----------------------------|--------------------------------|
| Paradigma            | Distancia (euclidiana)   | Densidad local             | Probabilístico (gaussiano)     |
| Forma de clusters    | Esférica, convexa        | Arbitraria, irregular      | Elíptica (covarianza flexible) |
| Requiere $k$ inicial | Sí ( $k = 3$ )           | No                         | Sí ( $k = 3$ )                 |
| Manejo de outliers   | Los absorbe al centroide | Los etiqueta como ruido    | Les asigna baja probabilidad   |
| Salida del modelo    | Etiqueta dura (0, 1, 2)  | Etiqueta dura + ruido (-1) | Probabilidad por cluster       |
| Ventaja clave        | Línea base interpretable | Identifica casos raros     | Incertidumbre por feto         |

## 7. Métricas de Evaluación

Evaluamos la calidad del clustering en dos niveles complementarios: métricas internas (coherencia geométrica sin usar etiquetas) y métricas externas (comparación con la clasificación clínica de referencia).

### 7.1 Métricas internas

**Silhouette Score**  $[-1, 1]$ . Para cada observación mide la diferencia entre su distancia media al propio cluster y al cluster vecino más cercano, normalizada por el máximo de ambas. Un valor próximo a 1 indica buena asignación; cercano a 0, punto en la frontera; negativo, posible mala asignación. Reportamos tanto el promedio global como los diagramas de silueta individuales.

**Davies-Bouldin Index**  $[0, +\infty)$ . Para cada cluster calcula la ratio entre su dispersión interna y su distancia al cluster más similar. El valor global es el promedio de esas ratios; valores menores indican clusters simultáneamente compactos y bien separados.

**Calinski-Harabász Index**  $[0, +\infty)$ . Evalúa la relación entre la varianza entre clusters y la varianza dentro de los clusters, ponderada por el número de observaciones y grupos. Valores mayores indican mejor definición de la partición.

### 7.2 Métricas externas

Dado que el dataset incluye la etiqueta `fetal_health`, disponemos de una referencia externa de alta calidad para cuantificar en qué medida los grupos descubiertos coinciden con la clasificación clínica.

**Adjusted Rand Index (ARI)**  $(-1, 1]$ . Mide la proporción de pares de observaciones con el mismo tratamiento en ambas particiones, corregida por azar. Un ARI de 1 indica concordancia perfecta; 0 equivale a asignación aleatoria.

**Normalized Mutual Information (NMI)**  $[0, 1]$ . Captura la información compartida entre la partición generada y las etiquetas reales, normalizada para eliminar el sesgo por número de clusters. Complementa al ARI al capturar dependencias estadísticas más generales.

**Cuadro 3:** Resumen de métricas de evaluación utilizadas.


| Métrica                 | Tipo    | Rango óptimo   | Qué mide                                           |
|-------------------------|---------|----------------|----------------------------------------------------|
| Silhouette Score        | Interna | Cercano a +1   | Cohesión interna y separación entre clusters       |
| Davies-Bouldin Index    | Interna | Mínimo posible | Similitud promedio entre clusters adyacentes       |
| Calinski-Harabász Index | Interna | Máximo posible | Relación varianza inter/intra cluster              |
| ARI                     | Externa | Cercano a +1   | Concordancia con etiquetas clínicas (correg. azar) |
| NMI                     | Externa | Cercano a 1    | Información compartida con diagnóstico real        |

## 8. Resultados de Clustering

### 8.1 K-Means++

Entrenamos K-Means++ con  $k = 3$ , `init='k-means++'`, `n_init=20` y `random_state=42`. Las métricas internas obtenidas se muestran en la Tabla 4.

La Figura 9 muestra los clusters encontrados proyectados sobre los dos primeros componentes principales, junto con la distribución de etiquetas clínicas reales para comparación directa.




**Figura 9:** K-Means++ ( $k = 3$ ) en PCA 2D. Izquierda: clusters encontrados con centroides marcados (X). Derecha: etiquetas clínicas reales.

La comparación entre los dos paneles revela que K-Means++ logra separar una región compacta hacia la derecha del espacio PCA (Cluster 2,  $n = 216$ , verde) que corresponde razonablemente con los casos Patológicos y parte de los Sospechosos. Sin embargo, los Clusters 0 ( $n = 1,017$ ) y 1 ( $n = 880$ ) se solapan considerablemente en el espacio PCA, lo que refleja que la frontera entre los estados Normal y Sospechoso no es geoméricamente nítida en las dos dimensiones de visualización. Este solapamiento es esperable dado que PC1 y PC2 capturan solo el 47 % de la varianza total.

El diagrama de silueta individual (Figura 10) cuantifica la cohesión interna de cada cluster.






**Figura 10:** Silhouette plot para K-Means++ ( $k = 3$ ). Cada barra representa un registro; la línea discontinua indica el promedio global ( $Avg = 0.178$ ).

El Silhouette Score promedio de 0.178 confirma que la separación entre clusters es modesta. El Cluster 2 ( $n = 216$ ) presenta los coeficientes más altos y uniformes, indicando que es el grupo más compacto e internamente coherente, lo que coincide con la hipótesis de que agrupa principalmente casos Patológicos. El Cluster 1 ( $n = 880$ ) tiene una distribución más ancha pero mayoritariamente positiva. El Cluster 0 ( $n = 1,017$ ) es el más grande y muestra una proporción notable de coeficientes negativos o cercanos a cero, señal de que muchos de sus registros se encuentran en la zona de frontera con el Cluster 1, lo cual es consistente con la ambigüedad entre los estados Normal y Sospechoso.

## 8.2 DBSCAN

Con la configuración  $\varepsilon = 3,155$  y  $\text{min\_samples} = 5$ , DBSCAN produjo un resultado que revela una limitación fundamental del algoritmo en este dataset. La Figura 11 muestra los clusters resultantes en PCA 2D junto con el silhouette plot calculado sobre los puntos no clasificados como ruido.



**Figura 11:** DBSCAN ( $\epsilon = 3,155$ ,  $\text{min\_s} = 5$ ) en PCA 2D (izquierda) y silhouette plot sin puntos de ruido (derecha,  $\text{Avg} = 0.165$ ). Los puntos amarillos son ruido; el Cluster 0 concentra el 94.8 % de los registros no clasificados como ruido.


El resultado es una partición fuertemente degenerada: un único cluster dominante (Cluster 0,  $n = 2,017$ , el 94.8 % de los puntos no-ruido) absorbe prácticamente todo el dataset, mientras que los cinco clusters restantes son micro-grupos de entre 5 y 9 registros (Cluster 1:  $n = 5$ , Cluster 2:  $n = 6$ , Cluster 3:  $n = 9$ , Cluster 4:  $n = 5$ , Cluster 5:  $n = 6$ ). Estos micro-clusters aparecen en los márgenes del espacio PCA 2D, especialmente hacia PC1 positivo y PC2 negativo, y corresponden a registros fisiológicamente extremos que DBSCAN aísla como grupos de alta densidad local pero separados del grueso de los datos.

Este comportamiento es una consecuencia directa de la naturaleza del dataset. Como anticipamos en el análisis de varianza explicada de PCA, la información está distribuida de forma uniforme en 21 dimensiones sin un subespacio de baja dimensión dominante. En un espacio de alta dimensión, las distancias euclidianas entre registros tienden a homogeneizarse (maldición de la dimensionalidad), lo que dificulta que DBSCAN encuentre fronteras de densidad claras que separen grupos clínicamente distintos. El resultado práctico es que  $\epsilon = 3,155$  es lo suficientemente grande para que casi todos los registros normales y sospechosos formen una única región continua de alta densidad, mientras que solo los casos más extremos quedan aislados como micro-clusters o ruido.

El silhouette plot (derecha) confirma esta interpretación: el Cluster 0 ( $n = 2,017$ ) presenta una distribución con muchos coeficientes negativos y cercanos a cero, con un promedio global de apenas 0.165, inferior al de K-Means++ (0.178). Las barras de los micro-clusters aparecen en la parte superior del gráfico como líneas casi horizontales en coeficientes altos, lo que refleja que esos grupos pequeños son internamente muy cohesionados pero representan casos atípicos, no los tres estados clínicos de interés. DBSCAN cumple su función de identificar outliers clínicamente extremos, pero no logra la segmentación en tres grupos que el problema requiere.

### 8.3 GMM


El GMM con `covariance_type='full'` y `n_init=20` convergió asignando el Componente 0 al 10.2 % de los registros ( $n = 216$ ), el Componente 1 al 40.3 % ( $n = 851$ ) y el Componente 2 al 49.5 % ( $n = 1,046$ ). La Figura 12 compara la asignación hard, el mapa de incertidumbre y las etiquetas clínicas reales.



**Figura 12:** GMM ( $k = 3$ ) en PCA 2D. De izquierda a derecha: asignación hard por componente, mapa de incertidumbre ( $1 - P_{\max}$ ) y etiquetas clínicas reales.

La asignación hard muestra un solapamiento importante entre los tres componentes en el espacio PCA 2D, patrón similar al observado en K-Means. El panel de incertidumbre ( $1 - P_{\max}$ ) revela que la gran mayoría de registros tienen probabilidad máxima muy cercana a 1.0 (color amarillo claro dominante), con solo puntos aislados en el centro del espacio con incertidumbre moderada ( $\sim 0,4$ ). Esto indica que el GMM, pese a ser un modelo probabilístico, realiza asignaciones casi deterministas para este dataset: los componentes están suficientemente separados en el espacio de 21 dimensiones aunque no lo parezcan en la proyección PCA 2D.


La Figura 13 cuantifica este comportamiento por componente.



**Figura 13:** Probabilidades de pertenencia por componente en GMM ( $k = 3$ ). Cada barra corresponde a un registro ordenado de mayor a menor probabilidad. Los valores  $\mu$  indican la probabilidad media de cada componente sobre todo el dataset.

Los tres paneles muestran asignaciones prácticamente binarias. El Componente 0 ( $\mu = 0,102$ , 10.2 % asignados) presenta una barra rectangular perfecta en 1.0 sin ningún registro en zona de transición, lo que lo convierte en el grupo más determinista del modelo. Los Componentes 1 ( $\mu = 0,404$ ) y 2 ( $\mu = 0,494$ ) muestran una caída abrupta al final de la serie ordenada, con solo una fracción pequeña de registros con probabilidades intermedias. La ausencia de una zona amplia de ambigüedad confirma lo observado en el mapa de incertidumbre: la información en las 21 dimensiones es suficiente para que el EM converja a componentes bien separados.

El silhouette plot (Figura 14) permite comparar directamente la calidad geométrica del GMM frente a K-Means.



**Figura 14:** Silhouette plot para GMM ( $k = 3$ ). La línea negra discontinua es el promedio GMM ( $Avg = 0.130$ ); la línea gris punteada es el promedio de K-Means++ (0.178) como referencia comparativa.

El Silhouette Score promedio del GMM (0.130) es inferior al de K-Means++ (0.178), indicando que la partición resultante es geoméricamente menos compacta en términos de distancias euclidianas. El Componente 0 ( $n = 216$ ) presenta una proporción notable de coeficientes negativos, lo que contrasta con el comportamiento del Cluster 2 de K-Means que agrupaba un número similar de registros con mayor cohesión. El Componente 2 ( $n = 1,046$ ) es el de mejor desempeño, con la mayoría de sus barras por encima del promedio. Esta diferencia entre modelos es esperable: el GMM optimiza verosimilitud gaussiana, no distancias euclidianas, por lo que puede generar particiones con menor Silhouette pero mayor fidelidad a la forma real de las distribuciones en el espacio completo de 21 dimensiones.

#### 8.4 Tabla comparativa de métricas de clustering

**Cuadro 4:** Métricas internas y externas para los tres algoritmos de clustering. Flechas indican la dirección óptima de cada métrica.

| Modelo    | Silhouette ↑  | DBI ↓         | CHI ↑         | ARI ↑         | NMI ↑         |
|-----------|---------------|---------------|---------------|---------------|---------------|
| K-Means++ | <b>0.1781</b> | 1.8629        | <b>422.49</b> | <b>0.1699</b> | <b>0.2009</b> |
| DBSCAN    | 0.1650        | <b>0.7008</b> | 40.14         | 0.0700        | 0.0829        |
| GMM       | 0.1299        | 2.2075        | 310.11        | 0.0805        | 0.1248        |

Los valores en negrita indican el mejor resultado por métrica. K-Means++ lidera en cuatro de las cinco métricas (Silhouette, CHI, ARI y NMI), lo que lo convierte en el algoritmo con

---


mejor desempeño global para este dataset. DBSCAN obtiene el DBI más bajo (0.7008), pero este resultado refleja la cohesión interna del único cluster masivo ( $n = 2,017$ ) más que una segmentación clínicamente útil. El CHI de DBSCAN (40.14) es drásticamente inferior al de los otros dos modelos, confirmando que su partición no captura la estructura inter-cluster del dataset. GMM queda en posición intermedia en la mayoría de las métricas, con un ARI (0.0805) y NMI (0.1248) superiores a DBSCAN pero por debajo de K-Means++.

## 9. Modelos de Clasificación Supervisada

Complementamos el análisis no supervisado con tres clasificadores entrenados sobre el dataset preprocesado (`fetal_health_preprocessed.csv`), usando `fetal_health` como variable objetivo. La división es 80 % entrenamiento y 20 % prueba con estratificación para preservar la proporción de clases.


### 9.1 K-Nearest Neighbors (KNN)

KNN clasifica un punto nuevo según la clase mayoritaria de sus  $k$  vecinos más cercanos en el espacio estandarizado de 21 dimensiones. Evaluamos  $k \in \{1, \dots, 30\}$  mediante validación cruzada estratificada 5-fold maximizando el F1-macro.



**Figura 15:** F1-macro en validación cruzada 5-fold para KNN con  $k = 1, \dots, 30$ . La banda sombreada representa  $\pm 1$  desviación estándar entre folds. La línea roja marca el  $k$  óptimo ( $k = 3$ , F1-macro  $\approx 0.819$ ).

El F1-macro alcanza su máximo en  $k = 3$  con un valor de aproximadamente 0.819 en validación cruzada. La curva cae de forma monótona a partir de ese punto, estabilizándose alrededor de 0.76 para  $k \geq 20$ , lo que indica que vecindarios grandes diluyen la señal local al incorporar puntos de clases distintas. La banda de incertidumbre es amplia para valores bajos de  $k$  (mayor varianza entre folds) y se estrecha progresivamente conforme  $k$  crece, mostrando que modelos más simples son menos estables. El pico en  $k = 3$  sugiere que la estructura del dataset tiene fronteras de decisión localmente nítidas que se aprovechan mejor con vecindarios pequeños.




**Figura 16:** Matrices de confusión para KNN ( $k = 3$ , Accuracy = 0,903): conteos absolutos (izquierda) y normalizada por clase real (derecha).

Con Accuracy global de 0.903, KNN muestra un desempeño fuertemente asimétrico entre clases. La clase Normal tiene un recall del 0.98 (322 de 330 correctos), lo que refleja que los vecinos más cercanos de un registro Normal son casi siempre también Normales dado el dominio mayoritario de esa clase. La clase Sospechoso es la más problemática con recall de 0.62: el 33 % de los registros Sospechosos se clasifican como Normales (19 casos), lo que en un contexto clínico representa falsos negativos de alto riesgo. La clase Patológico obtiene recall de 0.69, con 5 casos mal asignados como Normal y 6 como Sospechoso. El error más crítico desde la perspectiva médica es precisamente la confusión entre Patológico y Normal (5 casos), ya que implica no detectar un feto en riesgo real.


## 9.2 Árbol de Decisión

El Árbol de Decisión aprende reglas de clasificación jerárquicas basadas en particiones binarias del espacio de características. Evaluamos profundidades máximas  $d \in \{1, \dots, 20\}$  con validación cruzada y criterio Gini, usando `class_weight='balanced'` para compensar el desbalance de clases.



**Figura 17:** F1-macro en validación cruzada 5-fold para el Árbol de Decisión con `max_depth` entre 1 y 20. La curva se estabiliza alrededor de  $d = 8$  y la línea roja marca la profundidad óptima ( $d = 19$ ).

La curva de selección muestra un comportamiento claro en dos fases. De  $d = 1$  a  $d = 5$  el F1-macro sube de forma pronunciada (de 0.40 a  $\sim 0,81$ ), capturando las particiones más informativas del espacio. A partir de  $d = 6$  la curva se aplana y muestra una **tendencia a la estabilización progresiva** en torno a 0.83, con variaciones mínimas hasta  $d = 20$ . La profundidad óptima seleccionada es  $d = 19$ , aunque prácticamente cualquier profundidad  $d \geq 8$  produce resultados equivalentes dentro del margen de variabilidad entre folds. La banda de incertidumbre se estrecha considerablemente a partir de  $d = 5$ , lo que indica que el modelo es estable para árboles de profundidad media y alta.




**Figura 18:** Top 15 variables más importantes según el criterio Gini del Árbol de Decisión. Las barras rojas marcan las cuatro variables cuya importancia supera el 50 % del máximo.

El gráfico de importancias revela una jerarquía clara con dos niveles bien diferenciados. Las cuatro variables rojas concentran la mayor parte de la capacidad discriminante del árbol: `histogram_mean` y `mean_value_of_short_term_variability` lideran con importancias de  $\approx 0,22$  cada una, seguidas de `percentage_of_time_with_abnormal_long_term_variability` ( $\approx 0,15$ ) y `abnormal_short_term_variability` ( $\approx 0,14$ ). Estas cuatro variables capturan dos dimensiones fisiológicas complementarias: la tendencia central de la FCF (histograma) y la variabilidad cardíaca tanto a corto como a largo plazo, que son precisamente los indicadores clínicos primarios del bienestar fetal. El resto de las 11 variables verdes tiene importancias inferiores a 0.06, lo que indica que el árbol podría simplificarse manteniendo solo las variables más discriminantes sin pérdida significativa de desempeño.

### 9.3 Perceptrón Multicapa (MLP)


El MLP es una red neuronal feedforward que aprende representaciones no lineales de los datos mediante retropropagación y Adam como optimizador. Evaluamos cuatro arquitecturas con validación cruzada 5-fold.





**Figura 19:** F1-macro en validación cruzada 5-fold para cuatro arquitecturas MLP. Las barras de error corresponden a  $\pm 1$  desviación estándar entre folds. La barra roja marca la arquitectura ganadora: (256, 128) con F1-macro = 0,8056.

Las cuatro arquitecturas muestran una mejora progresiva y consistente conforme aumenta la capacidad de la red: (64,) obtiene 0.7466, (128, 64) sube a 0.7609, (128, 64, 32) alcanza 0.7713, y la arquitectura (256, 128) lidera con 0.8056. Esta tendencia creciente indica que el dataset tiene suficiente complejidad para beneficiarse de mayor capacidad representacional. Las barras de error son comparables entre arquitecturas, lo que sugiere que la mejora es sistemática y no producto de varianza entre folds. La arquitectura seleccionada, (256, 128), es la más profunda y ancha del conjunto evaluado, con una primera capa de 256 neuronas que aprende representaciones ricas de las 21 variables y una segunda de 128 que las comprime antes de la capa de salida.




**Figura 20:** Curva de pérdida por época para el MLP (256, 128). Azul: log-loss de entrenamiento. Naranja discontinuo: 1 – Accuracy de validación. Ambas curvas convergen cerca de 0.05 sin cruzarse, confirmando ausencia de sobreajuste en las 62 épocas de entrenamiento.

La curva de pérdida muestra un entrenamiento limpio en tres fases. En las primeras 5 épocas la pérdida de entrenamiento cae abruptamente de 0.96 a  $\sim 0,30$ , mientras que el error de validación (1 – Accuracy) se establece rápidamente en torno a 0.10. De la época 5 a la 30 ambas curvas descienden de forma más gradual y paralela, sin divergir entre sí. A partir de la época 30 la convergencia es casi completa, con ambas métricas aproximándose a  $\sim 0,05$  hacia la época 62. La ausencia de cruce entre las curvas de entrenamiento y validación confirma que el modelo no incurre en sobreajuste, y que las 62 épocas de entrenamiento son suficientes para la convergencia sin necesidad de *early stopping* agresivo.

## 9.4 Fronteras de decisión en PCA 2D

Para visualizar cómo cada clasificador particiona el espacio de características, entrenamos versiones 2D de KNN y el Árbol de Decisión exclusivamente sobre los dos primeros componentes principales (PC1: 29.3 % de varianza, PC2: 17.1 %) y graficamos las fronteras resultantes sobre los datos de prueba (Figura 21).



**Figura 21:** Fronteras de decisión en PCA 2D para KNN ( $k = 3$ , izquierda) y Árbol de Decisión ( $\text{depth} = 19$ , derecha). Modelos entrenados solo en 2D para visualización; los resultados de prueba provienen de los modelos en 21 dimensiones.

La diferencia en la naturaleza geométrica de ambos clasificadores es inmediatamente visible. KNN genera fronteras suaves e irregulares con forma de “islas” que se adaptan localmente a la distribución de puntos: las regiones de Sospechoso (naranja) aparecen como zonas irregulares incrustadas dentro del dominio Normal (verde), y la región Patológico (rosa) ocupa el cuadrante inferior izquierdo con contorno no convexo. El Árbol de Decisión, en contraste, produce particiones estrictamente rectangulares y axis-aligned características de su mecanismo de cortes binarios por umbral: el espacio queda dividido en rectángulos con bordes paralelos a los ejes, lo que crea una estructura más rígida pero más interpretable. Ambos clasificadores coinciden en que la zona de PC1 negativo y PC2 negativo concentra la mayor densidad de casos Patológicos y Sospechosos, lo que es coherente con los mapas de clustering vistos anteriormente. Es importante recordar que estas visualizaciones están entrenadas en 2D (47 % de la varianza total) y subestiman la separabilidad real que los modelos alcanzan en el espacio completo de 21 dimensiones.

## 9.5 Tabla comparativa de clasificadores

**Cuadro 5:** Métricas comparativas de los tres clasificadores supervisados sobre el conjunto de prueba (20 % del dataset, estratificado). Flechas indican dirección óptima.

| Métrica ↑         | KNN    | Árbol de Decisión | MLP           |
|-------------------|--------|-------------------|---------------|
| Accuracy          | 0.9031 | 0.9173            | <b>0.9196</b> |
| F1-macro          | 0.7978 | <b>0.8618</b>     | 0.8461        |
| F1-weighted       | 0.8987 | 0.9156            | <b>0.9140</b> |
| F1 Normal (1)     | 0.9527 | 0.9475            | <b>0.9559</b> |
| F1 Sospechoso (2) | 0.6667 | <b>0.7523</b>     | 0.6869        |
| F1 Patológico (3) | 0.7742 | <b>0.8857</b>     | 0.8955*       |

\* El Árbol de Decisión lidera en F1-macro pero MLP supera levemente en F1 Patológico.

Los tres modelos alcanzan accuracies superiores al 90 %, pero la métrica más relevante para este problema es el F1-macro, que penaliza por igual los errores en las tres clases independientemente de su frecuencia. Bajo este criterio, el Árbol de Decisión lidera con 0.8618, seguido del MLP (0.8461) y KNN (0.7978). La clase Sospechoso es la más difícil en los tres modelos, con F1 entre 0.67 y 0.75, lo que refleja su posición de frontera entre Normal y Patológico y el impacto del desbalance de clases (solo el 14 % del dataset). Para la clase Patológico, la más crítica desde el punto de vista médico, el MLP obtiene el F1 más alto (0.8955) seguido muy de cerca por el Árbol de Decisión (0.8857), mientras que KNN queda más rezagado (0.7742).

---

## 10. Análisis y Conclusiones

---

### 10.1 Análisis de resultados de clustering

La Tabla 4 permite comparar los tres algoritmos de forma numérica y concreta. K-Means++ lidera en cuatro de las cinco métricas: Silhouette (0.1781), CHI (422.49), ARI (0.1699) y NMI (0.2009). Su CHI es más de diez veces superior al de GMM (310.11) y casi once veces el de DBSCAN (40.14), lo que confirma que su partición captura la mayor separación relativa entre grupos en el espacio de 21 dimensiones. El ARI de 0.1699 y el NMI de 0.2009 indican que, aunque la concordancia con el diagnóstico clínico es modesta en términos absolutos, es la más alta entre los tres algoritmos, lo que refleja que la distancia euclidiana en el espacio estandarizado captura parte de la estructura clínica.

DBSCAN obtiene el DBI más bajo (0.7008), pero como discutimos en la sección de resultados, este valor refleja la cohesión interna del único cluster masivo ( $n = 2,017$ ) más que una segmentación real. Su ARI de 0.0700 y NMI de 0.0829 son los más bajos del conjunto, confirmando que la partición degenerada que produce no recupera la estructura clínica del dataset. DBSCAN cumple un rol distinto en este análisis: sus micro-clusters y puntos de ruido identifican registros fisiológicamente extremos, lo que tiene valor como herramienta de detección de anomalías pero no como segmentación en tres estados de salud.

GMM queda en posición intermedia con ARI (0.0805) y NMI (0.1248) superiores a DBSCAN pero por debajo de K-Means++. Su Silhouette más bajo (0.1299) y su DBI más alto (2.2075) indican que, desde la perspectiva de distancias euclidianas, produce la partición geoméricamente menos compacta, aunque su naturaleza probabilística aporta información de incertidumbre por registro que los otros algoritmos no ofrecen.

Al analizar la evolución del desempeño conforme se refinaron el preprocesamiento y los hiperparámetros, observamos una **tendencia a la estabilización progresiva** en las métricas internas, particularmente en el Silhouette Score y el índice de Davies-Bouldin, lo que indica que los algoritmos alcanzaron particiones cercanas a su óptimo local en el espacio estandarizado y que ajustes adicionales de hiperparámetros no producirían mejoras sustanciales.

### 10.2 Análisis de resultados de clasificación

La Tabla 5 revela que ningún clasificador domina en todas las métricas, y la elección del mejor modelo depende del objetivo clínico priorizado.

El Árbol de Decisión (depth=19) obtiene el F1-macro más alto (0.8618) y lidera en F1 Sospechoso (0.7523) y F1 Patológico (0.8857), lo que lo convierte en el clasificador más equilibrado entre clases. Su ventaja sobre KNN y MLP en la clase Sospechoso es notable (+0.086 y +0.065 respectivamente), lo que sugiere que las reglas de partición jerárquicas capturan mejor la zona de transición entre los estados Normal y Sospechoso. El uso de `class_weight='balanced'` fue determinante para este resultado: sin ese ajuste, el árbol habría tendido a ignorar las clases minoritarias.

El MLP (256, 128) compite estrechamente con el árbol: su Accuracy es marginalmente superior (0.9196 vs 0.9173) y obtiene el mejor F1 en las clases Normal (0.9559) y Patológico (0.8955). Desde una perspectiva clínica, el F1 Patológico es la métrica más crítica ya que mide la capacidad de detectar fetos en riesgo real. En este sentido el MLP es el modelo más seguro,

aunque su F1-macro global es 0.016 inferior al del árbol por su menor desempeño en la clase Sospechoso (0.6869).

KNN queda en tercer lugar en F1-macro (0.7978), principalmente por su F1 Patológico de 0.7742, el más bajo del conjunto. Su recall de 0.69 en Patológico (matriz de confusión) implica que 11 de cada 35 fetos patológicos son mal clasificados, lo que en un contexto de apoyo diagnóstico es una limitación relevante. KNN es el clasificador más sencillo de implementar e interpretar, pero los datos sugieren que la complejidad adicional del árbol o el MLP está justificada para este problema.

### 10.3 Conclusiones sobre los modelos

Para el problema de clustering, K-Means++ es el algoritmo más adecuado según las métricas obtenidas: lidera en Silhouette (0.1781), CHI (422.49), ARI (0.1699) y NMI (0.2009), ofreciendo la partición que mejor combina cohesión interna e interpretabilidad clínica. Los tres modelos tienen roles complementarios: DBSCAN es preferible para detectar registros extremos o atípicos, y GMM aporta la única salida probabilística del conjunto, útil cuando se requiere cuantificar la incertidumbre diagnóstica por registro. Un hallazgo transversal importante es que los valores absolutos de ARI y NMI son bajos en los tres algoritmos (máximo 0.1699), confirmando que el dataset no tiene una estructura naturalmente separable en tres grupos discretos: la clasificación Normal/Sospechoso/Patológico es una convención diagnóstica sobre un espacio continuo.

Para la clasificación supervisada, el Árbol de Decisión es la elección más equilibrada cuando se optimiza el F1-macro global (0.8618), mientras que el MLP es preferible si la prioridad es minimizar los falsos negativos en la clase Patológico ( $F1 = 0.8955$ ). La brecha entre los tres clasificadores y el clustering no supervisado es sustancial: el mejor F1-macro supervisado (0.8618) supera ampliamente al mejor ARI no supervisado (0.1699), lo que cuantifica de forma concreta el valor de las etiquetas clínicas en este problema. El acceso a las etiquetas transforma un problema de estructura ambigua en uno donde los clasificadores logran más del 91 % de accuracy con tres modelos relativamente simples.

### 10.4 Limitaciones

Entre las limitaciones del estudio destacamos el desbalance severo de clases (78 % Normal), que afecta especialmente a la clase Sospechoso en todos los modelos supervisados (F1 máximo de 0.75) y limita la capacidad de los algoritmos de clustering para recuperar la estructura de las clases minoritarias. La elección de  $\epsilon$  en DBSCAN es sensible al preprocesamiento, y el resultado degenerado obtenido (un cluster de 2,017 registros) sugiere que el algoritmo no es adecuado para este dataset en su configuración actual. La alta multicolinealidad entre las variables del histograma implica que PCA mezcla señales clínicas distintas en los mismos componentes, lo que puede limitar la separabilidad en la proyección 2D. Finalmente, el MLP y el Árbol de Decisión con profundidad 19 son modelos de caja negra o semitransparente: sus predicciones son difíciles de justificar directamente ante un clínico sin herramientas adicionales de explicabilidad.

---

## 10.5 Sugerencias para trabajos futuros

Futuras investigaciones podrían explorar el uso de UMAP en lugar de PCA para la reducción de dimensionalidad previa al clustering, dado que preserva mejor la estructura global de manifolds no lineales y podría revelar separaciones que PCA no captura. En clasificación, técnicas de re-muestreo como SMOTE o ensambles como Random Forest y XGBoost podrían mejorar el F1 en la clase Sospechoso sin sacrificar el desempeño en Normal. También resultaría valioso incorporar información demográfica de las pacientes (edad gestacional, paridad) para enriquecer tanto la segmentación como la clasificación. Finalmente, la aplicación de métodos de explicabilidad como SHAP sobre el MLP y el árbol permitiría presentar las predicciones de forma comprensible para los obstetras, cerrando la brecha entre el desempeño numérico y la utilidad clínica real.

## 11. Notebooks de Google Colab

---

El código completo está organizado en dos notebooks de Google Colab accesibles en los siguientes enlaces:

- **Notebook 1 (Preprocesamiento y Clustering):** <https://colab.research.google.com/drive/15w12SdGWN9Dn1iYLEXqm9STfHdevR4Bz?usp=sharing>
- **Notebook 2 (Clasificación supervisada):** <https://colab.research.google.com/drive/1HJQhbLI2SE2hSL0ELD5I6LaU1-L9VZRt?usp=sharing>